

RELATÓRIO ANALÍTICO: ARQUITETURA (CSV) vs. MODELAGEM DIMENSIONAL (DATA WAREHOUSE)

Disciplina: Business Intelligence

Professor: Otávio Lube

Autor: Mateus Gazott Oliveira

1. TABELA COMPARATIVA DE MÉTRICAS EMPÍRICAS


Aferições registradas em laboratório durante a execução de ambas as versões do painel gerencial:

Métrica Aferida	Versão CSV (Amostra: 500 mil linhas)	Versão DW (Base Completa: ~5.19M linhas)	Vantagem / Fator de Otimização
Tempo de Carga Inicial	~4.850 s	~0.045 s (Conexão via Pool)	107x mais rápido no DW
Tempo de Carga c/ Cache	~0.002 s (Leitura em RAM)	~0.001 s (Cache do SQLAlchemy)	Equivalente
Filtragem Global de KPI	~215.4 ms	~14.2 ms	15.1x mais rápido no DW
Renderização da Série Temporal	~185.0 ms	~31.8 ms	5.8x mais rápido no DW
Renderização do Heatmap de Cidades	~342.1 ms	~42.0 ms	8.1x mais rápido no DW
Consumo de Memória RAM na Aplicação	~185.0 MB (Alocado no Python)	< 4.5 MB (Apenas o Cursor SQL)	Economia de 97.5% de RAM

2. MODELO ESTRELA

Diagrama (Modelo Estrela) O diagrama apresentado representa a estrutura dimensional do Data Warehouse desenvolvido para análise das notificações de COVID-19. O modelo segue a arquitetura Star Schema (Esquema Estrela), na qual a tabela central FATO_NOTIFCOVID armazena os eventos e indicadores principais das notificações, enquanto as tabelas de dimensão fornecem informações descritivas que permitem diferentes tipos de análises.

A tabela fato registra dados como idade do paciente, dias até o encerramento da notificação, dias até o óbito, confirmação do caso e outras métricas relevantes. Ela está conectada às dimensões Tempo, Localidade, Perfil do Paciente, Classificação, Sintomas, Comorbidades e Teste, que armazenam informações complementares sobre cada notificação.



4. ATIVIDADE.

4.1 Quando o DW é vantajoso? Quando o CSV ainda é competitivo?

O **Data Warehouse (DW)** é mais vantajoso quando trabalhamos com grandes volumes de dados, como os mais de 5 milhões de registros do dataset COVID-19. Nesse cenário, o banco de dados consegue processar consultas de forma mais eficiente, sem sobrecarregar a memória do computador do usuário. Além disso, o DW é ideal quando vários usuários acessam os dados ao mesmo tempo e quando são necessárias consultas complexas envolvendo filtros, agrupamentos e cruzamento de informações.

Por outro lado, o **CSV** continua sendo uma boa opção em análises rápidas e exploratórias, principalmente durante o desenvolvimento inicial do projeto. Para arquivos pequenos e estáticos, a leitura direta do CSV pode ser mais simples e rápida do que configurar e conectar um banco de dados.

4.2. Qual o impacto da modelagem dimensional na performance de consultas analíticas?

A modelagem dimensional melhorou significativamente o desempenho das consultas. No projeto, o tempo de resposta caiu de aproximadamente **342 ms para 42 ms**.

Isso acontece porque o modelo estrela utiliza:

- **Chaves substitutas (Surrogate Keys)**, que são números inteiros mais rápidos para pesquisa do que textos.
- **Tabela fato com medidas numéricas**, facilitando cálculos e agregações.
- **Dimensões organizadas**, reduzindo a quantidade de junções necessárias nas consultas.

Dessa forma, o banco consegue localizar e processar as informações muito mais rapidamente.

4.3. Como a estratégia de cache (st.cache_data) muda o cenário?

O cache melhora bastante o desempenho da aplicação, mas seu efeito é diferente em cada arquitetura.

No caso do **CSV**, o cache evita que o arquivo seja lido novamente a cada interação do usuário, reduzindo o tempo de carregamento. Porém, os cálculos e filtros ainda precisam ser refeitos sobre todos os dados armazenados em memória.

No caso do **Data Warehouse**, o cache armazena apenas os resultados das consultas SQL. Assim, quando o usuário faz uma solicitação já realizada anteriormente, o resultado é exibido instantaneamente sem executar novamente a consulta no banco.

Portanto, o cache traz benefícios para ambas as abordagens, mas seu aproveitamento é maior quando combinado com o Data Warehouse.

4.4. Quais são os trade-offs operacionais (manutenção, evolução e governança)?

A utilização de um **CSV** apresenta menor complexidade de manutenção, pois basta substituir o arquivo quando houver atualização dos dados. Entretanto, essa abordagem possui limitações para crescimento do projeto e controle de qualidade das informações.

Já o **Data Warehouse** exige maior esforço inicial e manutenção contínua do banco de dados, porém oferece diversas vantagens:

- Facilidade para adicionar novas tabelas e fontes de dados.
- Melhor organização das informações.
- Controle de integridade através de chaves e relacionamentos.
- Maior confiabilidade e padronização dos dados.
- Melhor suporte para auditoria e governança.

Em resumo, o CSV é mais simples e rápido para projetos pequenos, enquanto o Data Warehouse é a melhor escolha para sistemas analíticos maiores, que exigem desempenho, escalabilidade e qualidade dos dados.

5. CONCLUSÃO

O desenvolvimento deste projeto demonstrou que a utilização de um Data Warehouse integrado ao PostgreSQL é uma solução mais eficiente para análise de grandes volumes de dados quando comparada ao uso direto de arquivos CSV.

Os testes realizados mostraram que o Data Warehouse apresentou melhor desempenho nas consultas, reduzindo significativamente o tempo de resposta da aplicação. Além disso, a modelagem dimensional facilitou a organização dos dados, a criação de análises mais complexas e a geração de indicadores para apoio à tomada de decisão.

Embora o uso de arquivos CSV seja uma alternativa simples e adequada para análises iniciais ou conjuntos de dados menores, essa abordagem apresenta limitações de escalabilidade, desempenho e governança quando aplicada a grandes volumes de informação.

Dessa forma, conclui-se que a adoção do Data Warehouse proporciona uma arquitetura mais robusta, organizada e preparada para futuras expansões, garantindo maior eficiência, confiabilidade e suporte às atividades de Business Intelligence.

